دانشگاه صنعتی شریف
دانشکده مهندسی برق

گزارش پروژه یادگیری عمیق

نگارش

پوریا اشرفیان (۹۶۱۰۱۲۲۷)

میلاد صمیمی‌فر (۴۰۰۲۰۵۵۷۷)

بهمن ۱۴۰۰

فهرست مطالب

فصل ۱ تشخیص اشیاء

در این قسمت از مدل آماده YOLO-v3 استفاده کردیم. این مدل با توجه به ساختاری که دارد در پردازش‌های real-time استفاده می‌شود و سرعت بالایی در یافتن اشیا دارد.

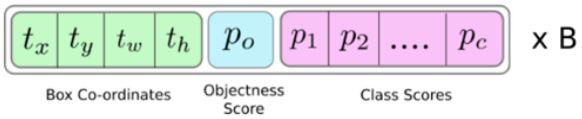

شکل ۱.۱: خروجی‌های شبکه YOLO-v3

همان طور که از تصویر ۱.۱ مشخص است خروجی این مدل حاوی مختصات box bounding های اشیای تشخیص داده شده‌است که در قسمت اتصال دو مدل تشخیص عمق و تشخیص اشیا از این خاصیت استفاده می‌کنیم.

در ادامه روش اصلی و مزیت‌های YOLO-v3 نسبت به ورژن‌های قبلی YOLO را بیان می‌کنیم. در این روش برای تشخیص صحیح‌تر داده هایی که دارای اشیا با پراکندگی اندازه‌های بالا[1] هستند، چند روش استفاده شده که یکی از این روش‌ها Predictions Across Scales نام دارد. برای این کار از مفهوم Feature Pyramid Networks بهره گرفته شده‌است. در این شبکه برای هر scale سه باکس پیش‌بینی می شود.

در مرحله بعد feature map دو لایه پیشین را با ضریب ۲ upsample کرده و با feature map خود ترکیب می‌کنیم (concatenate). با همین روش scale سوم را هم میسازیم. با توجه به این که در مرحله آخر از مراحل قبلی استفاده میکنیم، از محاسبات قبلی به نحو احسن استفاده می شود و مشکل پراکندگی اندازه های بالا کمتر پیش خواهد آمد. در شکل‌های ۲.۱ و ۳.۱ به ترتیب نمای کلی و ساختار شبکه YOLO-v3 آمده است.

معیار ارزیابی مدلی که ما استفاده کردیم mAP[2] است و مقدار آن برای این مدل ۵۷٫۹ درصد است. این مدل از pjreddie.com/darknet/yolo قابل دانلود است.

در شکل ۴.۱ تابع هزینه شبکه YOLO-v2 آمده‌است. در شبکه ما به جای مربعات از آنتروپی متقابل استفاده می‌شود. بنابراین به نوعی در این ورژن از logistic regression برای به محاسبه confidence و predictions استفاده می‌کنیم. مفهوم کلی این تابع هزینه به این معنی است که برای هر ground truth box باکس خود را تولید می‌کنیم به

[1] High Size Variation
[2] Mean Average Precision

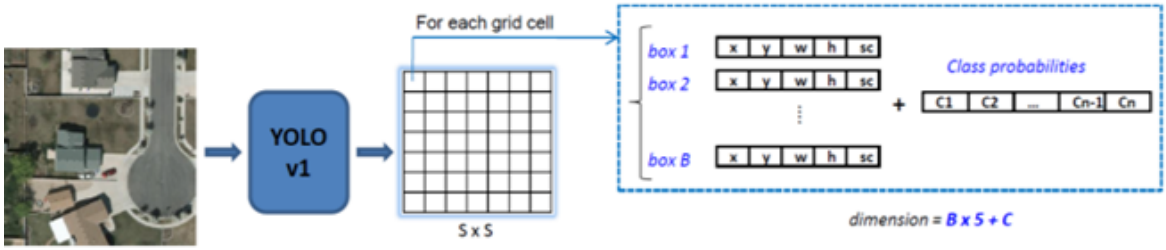

(a)

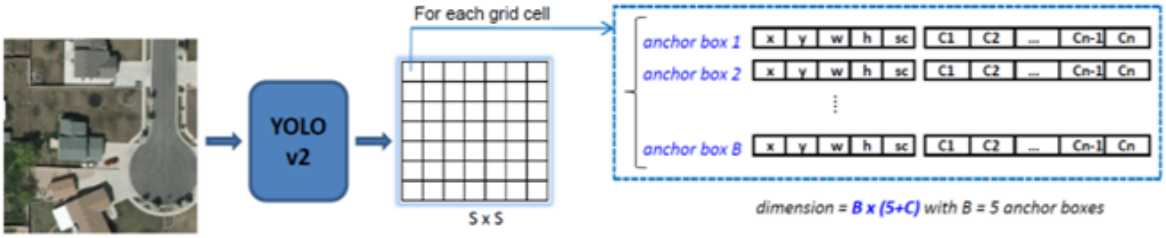

(b)

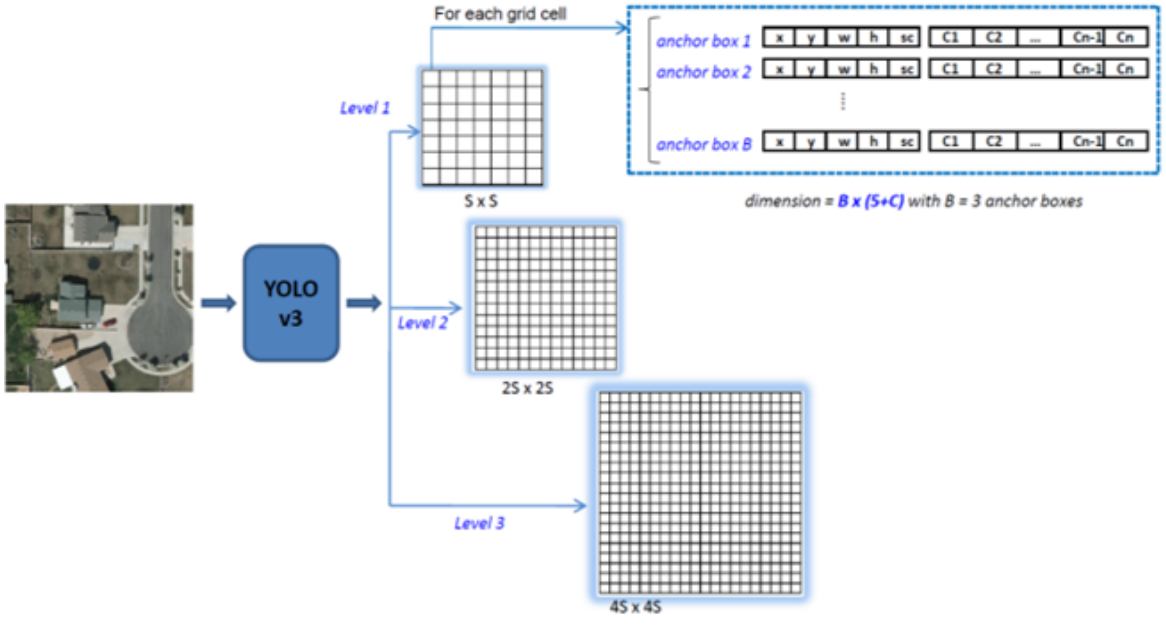

شکل ۲.۱: نمای کلی YOLO-v3

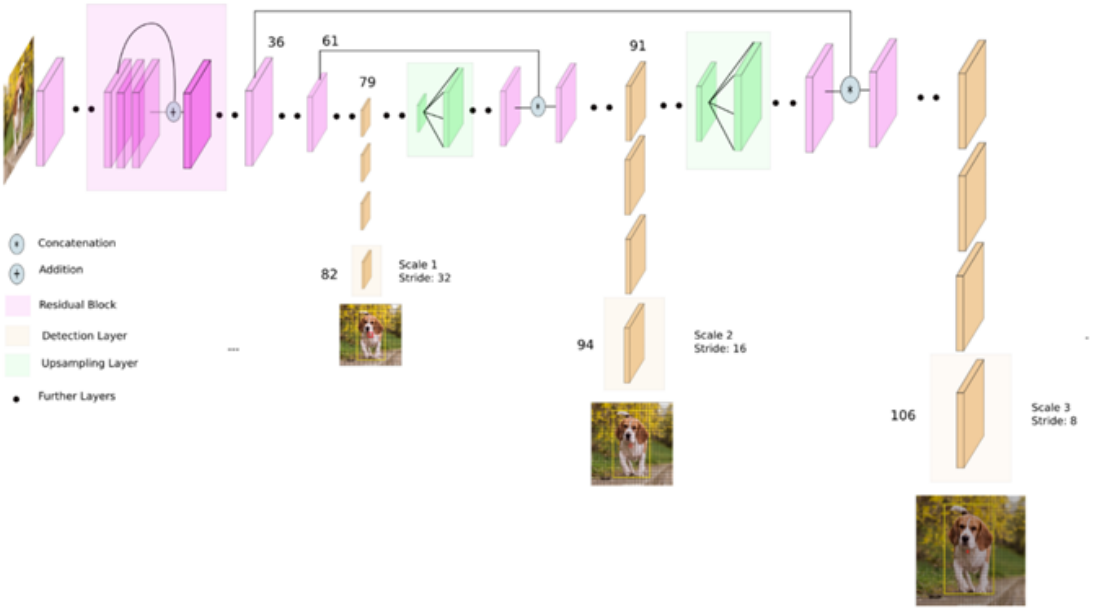

شکل ۳.۱: ساختار شبکه YOLO-v3

طوری که بیشترین همپوشانی را با باکس اصلی داشته باشد.

Regression loss

$$\lambda_{\textbf{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right]$$

$$+ \lambda_{\textbf{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right]$$

Confidence loss

$$+ \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left(C_i - \hat{C}_i \right)^2$$

$$+ \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{noobj}} \left(C_i - \hat{C}_i \right)^2$$

Classification loss

$$+ \sum_{i=0}^{S^2} \mathbb{1}_{i}^{\text{obj}} \sum_{c \in \text{classes}} \left(p_i(c) - \hat{p}_i(c) \right)^2$$

شکل ۴.۱: تابع هزینه YOLO-v2

فصل ۲ تشخیص عمق

۱.۲ ساختار CycleGAN

این روش اولین بار در [۱] ارائه شد. در این روش به دنبال یافتن دو تبدیل G و F هستیم که از دامنه تصاویر RGB به تصاویر عمق و برعکس کار می‌کنند. همچنین به دنبال این هستیم که این دو تبدیل معکوس یکدیگر باشند. تابع هزینه مورد استفاده در این روش در شکل ۱.۲ آمده‌است. علاوه بر شبکه‌های G و F، دو شبکه تمایزدهنده برای D_X و D_Y برای دامنه‌های تصاویر اصلی و تصاویر عمق وجود دارند که برخلاف شبکه های مولد عمل می‌کنند. ترم اول و دوم مربوط به این شبکه‌هاست و به صورت میانگین مربعات تفاضل پیکسل‌های لابه آخر با ماتریس یکانی محاسبه می‌شوند. ترم سوم برای اجبار به معکوس بودن تبدیل‌های مولد است و در شکل ۲.۲ آمده‌است.

$$\begin{aligned}\mathcal{L}(G, F, D_X, D_Y) =& \mathcal{L}_{\text{GAN}}(G, D_Y, X, Y) \\ &+ \mathcal{L}_{\text{GAN}}(F, D_X, Y, X) \\ &+ \lambda \mathcal{L}_{\text{cyc}}(G, F),\end{aligned}$$

شکل ۱.۲: تابع هزینه مورد استفاده در CycleGAN

$$\begin{aligned}\mathcal{L}_{\text{cyc}}(G, F) =& \mathbb{E}_{x \sim p_{\text{data}}(x)}[\|F(G(x)) - x\|_1] \\ &+ \mathbb{E}_{y \sim p_{\text{data}}(y)}[\|G(F(y)) - y\|_1].\end{aligned}$$

شکل ۲.۲: ترم هزینه مربوط به معکوس بودن

شبکه‌های G و F هر کدام شامل ۲ بلوک downsampling، پنج resblock و دو بلوک upsampling هستند. شبکه های D هم شامل سه بلوک downsampling هستند. جزئیات لایه‌های این شبکه‌ها در نوت بوک مربوطه وجود دارد. بهترین شبیه‌سازی انجام شده روی این مدل با بهینه‌ساز آدام، نرخ یادگیری ۰٫۰۰۰۲ و مقدار β_1 برابر با ۰٫۵ انجام شد. معیار ارزیابی RMS[1] بود که پس از ۲۰ مرحله آموزش با سایز بچ ۱ به ۰٫۳ روی داده‌های تست رسید. در طول آموزش ۱۱۰۰ تصویر برای آموزش و ۳۴۹ تصویر برای تست استفاده شدند. در شکل ۳.۲ نتیجه تست شبکه روی تعدادی

[1] Root Mean Squared

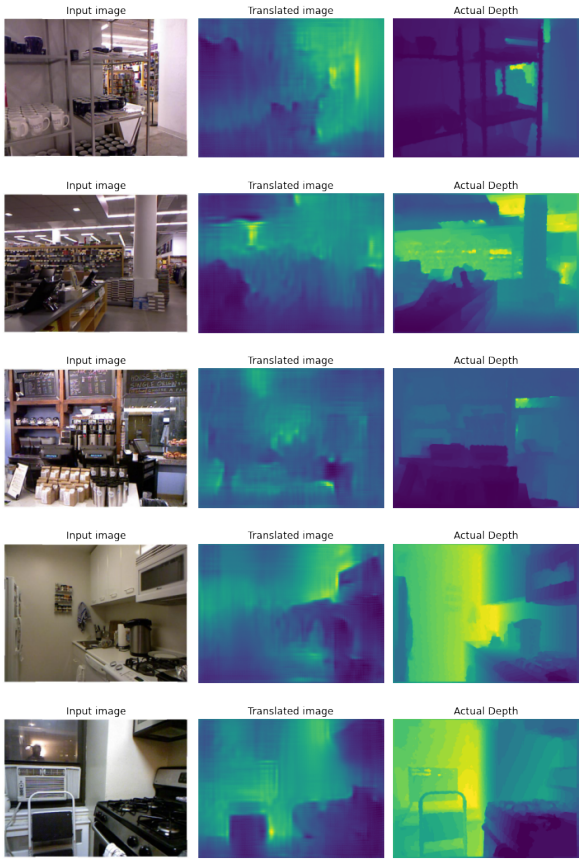

شکل ۳.۲: نتایج تست شبکه CycleGAN آموزش دیده

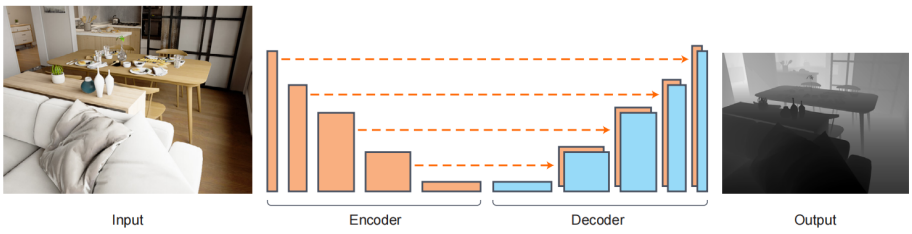

شکل ۴.۲: نمای کلی شبکه

از داده های تست آورده شده‌است. چون با شبیه سازی های متوالی نتایج به حد مطلوبمان نرسید به سراغ شبکه Unet رفتیم.

۲.۲ ساختار Unet

این ساختار را از [۲] برداشتیم. همان طور از در شکل ۴.۲ دیده می‌شود، شبکه شامل یک انکودر و دکودر است. انکودر شبکه شامل یک تقطیع از شبکه DenseNet-169 است. انکودر ورودی را به یک بردار ویژگی تبدیل می‌کند، سپس دکودر با upsampleهای متوالی آن را به تصویر عمق خروجی تبدیل می‌کند. جزئیات لایه‌ها در جدول ۱.۲ و در نوت‌بوک مربوطه وجود دارند.

جدول ۱.۲: لایه های شبکه؛ تا قبل از لایه UP1 تمام لایه ها، لایه های DenseNet-169 هستند.

LAYER	OUTPUT	FUNCTION
INPUT	$480 \times 640 \times 3$	
CONV1	$240 \times 320 \times 64$	DenseNet CONV1
POOL1	$120 \times 160 \times 64$	DenseNet POOL1
POOL2	$60 \times 80 \times 128$	DenseNet POOL2
POOL3	$30 \times 40 \times 256$	DenseNet POOL3
...	...	...
CONV2	$15 \times 20 \times 1664$	Convolution 1×1 of DenseNet BLOCK4
UP1	$30 \times 40 \times 1664$	Upsample 2×2
CONCAT1	$30 \times 40 \times 1920$	Concatenate POOL3
UP1-CONVA	$30 \times 40 \times 832$	Convolution 3×3
UP1-CONVB	$30 \times 40 \times 832$	Convolution 3×3
UP2	$60 \times 80 \times 832$	Upsample 2×2
CONCAT2	$60 \times 80 \times 960$	Concatenate POOL2
UP2-CONVA	$60 \times 80 \times 416$	Convolution 3×3
UP2-CONVB	$60 \times 80 \times 416$	Convolution 3×3
UP3	$120 \times 160 \times 416$	Upsample 2×2
CONCAT3	$120 \times 160 \times 480$	Concatenate POOL1
UP3-CONVA	$120 \times 160 \times 208$	Convolution 3×3
UP3-CONVB	$120 \times 160 \times 208$	Convolution 3×3
UP4	$240 \times 320 \times 208$	Upsample 2×2
CONCAT3	$240 \times 320 \times 272$	Concatenate CONV1
UP2-CONVA	$240 \times 320 \times 104$	Convolution 3×3
UP2-CONVB	$240 \times 320 \times 104$	Convolution 3×3
CONV3	$240 \times 320 \times 1$	Convolution 3×3

۸۰ درصد داده‌ها برای آموزش استفاده شدند، ۱۰ دصد برای اعتبارسنجی و ۱۰ درصد برای تست. معیار ارزیابی روش ما با مقاله فرق دارد. صحت ما به این صورت تعریف می شود که خروجی پیکسل‌های خروجی شبکه (که خروجی یک تابع سیگوید هستند) به نزدیک ترین عدد صحیح (۰ تا ۱) گرد می‌شوند. سپس همین اتفاق برای پیکسل‌های خروجی واقعی (که مقادیرشان بین صفر و ۱ نرمالیزه شده‌اند) انجام می‌شود. مقادیر حاصل در پیکسل‌ها تک به تک مقایسه می‌شوند و درصد درستی به عنوان صحت گزارش می‌شود.

تابع هزینه شبکه همراه با تعریف هر ترم آن در تصویر زیر ۵.۲ آمده‌است. ترم اول هزینه L1 نقطه به نقطه است. ترم دوم تابع هزینه L1 است که برای گرادیان‌های تصویر به صورت جداگانه روی مولفه های x و y محاسبه شده‌است. ترم سوم هم شباهت ساختاری است که یک تابع هزینه رایج در بازسازی تصاویر است. مقدار λ هم برابر با ۰/۱ در نظر گرفتیم.

شبکه را با نرخ یادگیری آموزش ۰/۰۰۰۱، سایز بچ ۴ و بهینه‌ساز آدام آموزش دادیم. بعد از ۱۰ مرحله آموزش حدود ۸۴ درصد صحت روی داده‌های تست بدست آمد که درصد معقولی است. در شکل ۶.۲ سه نمونه از تست‌های شبکه آورده شده‌است.

$$L(y, \hat{y}) = \lambda L_{depth}(y, \hat{y}) + L_{grad}(y, \hat{y}) + L_{SSIM}(y, \hat{y}).$$

$$L_{depth}(y, \hat{y}) = \frac{1}{n} \sum_{p}^{n} |y_p - \hat{y}_p|.$$

$$L_{grad}(y, \hat{y}) = \frac{1}{n} \sum_{p}^{n} |\boldsymbol{g}_{\mathbf{x}}(y_p, \hat{y}_p)| + |\boldsymbol{g}_{\mathbf{y}}(y_p, \hat{y}_p)|$$

$$L_{SSIM}(y, \hat{y}) = \frac{1 - SSIM(y, \hat{y})}{2}.$$

شکل ۵.۲: تابع هزینه شبکه Unet

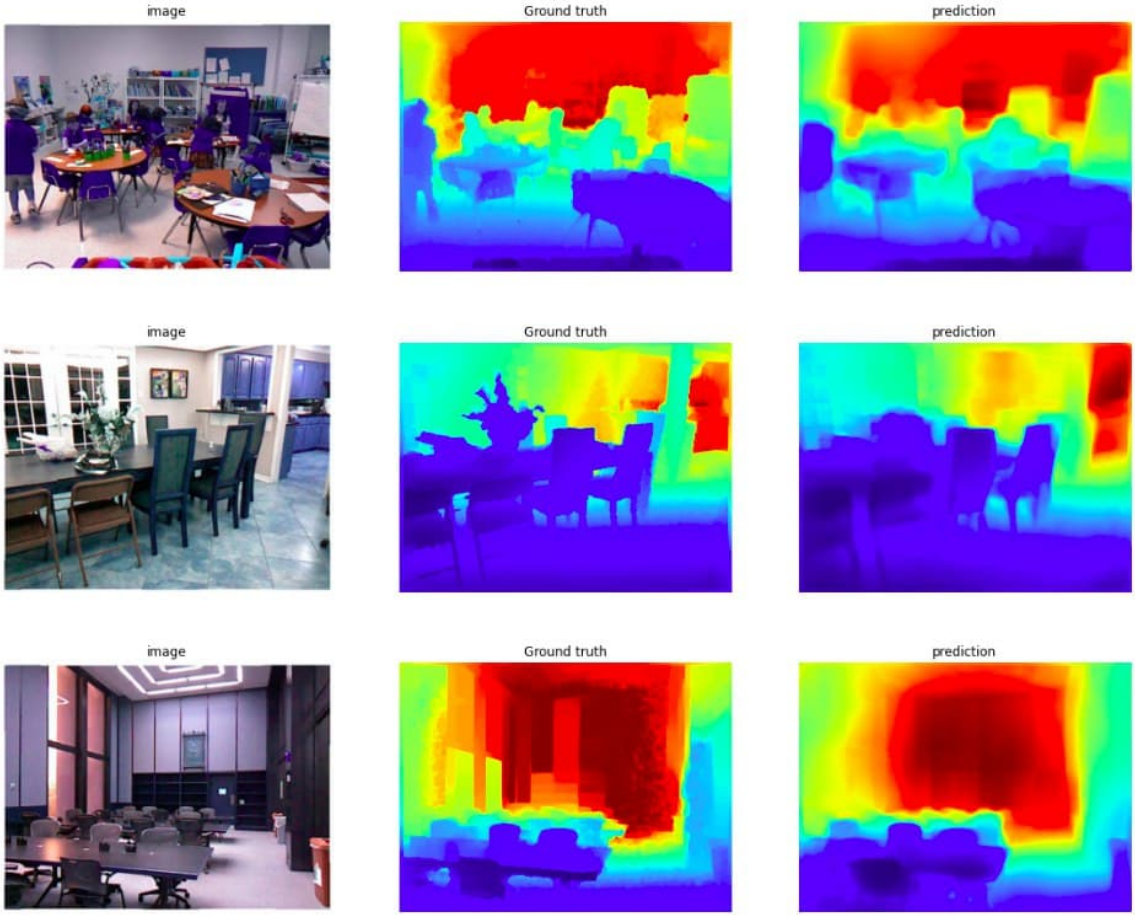

شکل ۶.۲: سه نمونه از تست های شبکه آموزش دیده

فصل ۳ آموزش مشترک

در روش های مورد استفاده ما، شبکه‌های تشخیص اشیا و تشخیص عمق به صورت جداگانه از هم آموزش داده شده‌اند. در خصوص اینکه آیا می توان شبکه ها را به صورت همزمان با هم آموزش داد و به دقت مطلوب رسید، ما تحقیقاتی انجام دادیم. در این رابطه ما با یک مسئله یادگیری چندوظیفه‌ای[1] طرف هستیم. جواب سوال احتمالا این است که می توانیم به همان دقت مطلوب یا حتی بیشتر برسیم.

در مورد یادگیری چندوظیفه‌ای مقالات مروری [۳] و [۴] را مطالعه کردیم. طبق [۳] دو روش کلی برای آموزش مشترک شبکه‌های عصبی عمیق برای چند وظیفه وجود دارد.

اولی که اشتراک وزن سخت نام دارد، به این صورت است که تا تعدادی لایه، داده‌های موجود در تمام وظایف از لایه های مشابه می‌گذرند و از جایی به بعد لایه‌های مخصوص وظایف وارد کار می‌شوند. در حالت دوم که اشتراک وزن نرم نام دارد، هر وظیفه مدل خود را دارد، با وزن‌های و پارامترهای مخصوص خود. در این روش قیدی رو وزن های مدل‌های مختلف گذاشته می‌شود تا وزن ها از هم فاصله زیادی نگیرند. در شکل‌های ۱.۳ و ۲.۳ این حالت‌ها نمایش داده شده‌اند.

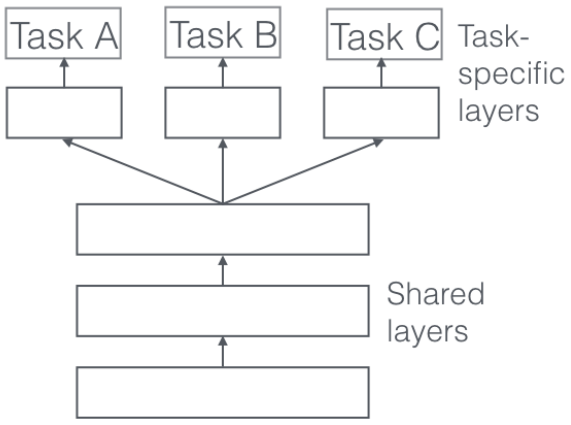

شکل ۱.۳: اشتراک وزن سخت

یادگیری چندوظیفه‌ای چند حسن دارد از جمله:

- افزایش تعداد داده‌های آموزشی: در این روش‌ها به دلیل استفاده از داده‌های موجود در چند وظیفه مختلف، در

[1] Multi-Task Learning

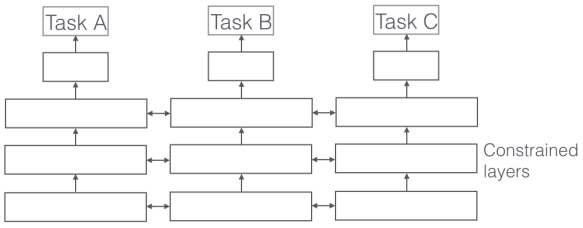

شکل ۲.۳: اشتراک وزن نرم

صورت استفاده از یک ساختار مشترک تعداد داده‌های آموزشی ما خیلی بیشتر می شوند.

- تمرکز بیشتر روی ویژگی‌های اساسی: این مدل‌ها معمولا نسبتا نویز مقاومت خیلی بیشتری نشان می‌دهند.
- یادگیری ویژگی‌های راحت‌تر از دیگر وظایف: در این مدل‌ها معمولا ویژگی‌های مشترک بین وظایف به آموزش بهتر مدل کمک می‌کنند.
- رگولاریزاسیون: در این مسائل با اظافه شدن یک بایاس به مدل به دلیل وجود وظایف مختلف، احتمال بیش‌برازش و فیت شدن به نویز کمتر می‌شود.

در مطالعات ما، مقاله‌ای که از معیار ارزیابی مشترک برای مدل آموزش دیده استفاده کند یافت نشد. روال کار همه مقالات به این صورت بود شبکه‌ها به صورت مشترک و جداگانه آموزش می‌دیدند، و نهایتا با معیار ارزیابی هر وظیفه به صورت جداگانه ارزیابی می‌شدند. با این تمام مقالات در حالت آموزش مشترک از یک **تابع هزینه مشترک** برای آموزش استفاده می‌کردند. برای مثال در [۵] از جمع وزن دار سه تابع هزینه جداگانه برای وظایف sematic segmentation، instance segmentation و تشخیص عمق استفاده می‌شود. برای وظیفه اول از آنتروپی متقابل پیکسل به پیکسل، برای وظیفه دوم از نرم L_1 تفاضل instance های یافت شده و برای وظیفه سوم از نرم L_1 تفاضل پیکسل به پیکسل استفاده شده‌است. در شکل ۳.۳ یک نمونه‌ای از نتایج این مقاله آورده شده‌است.

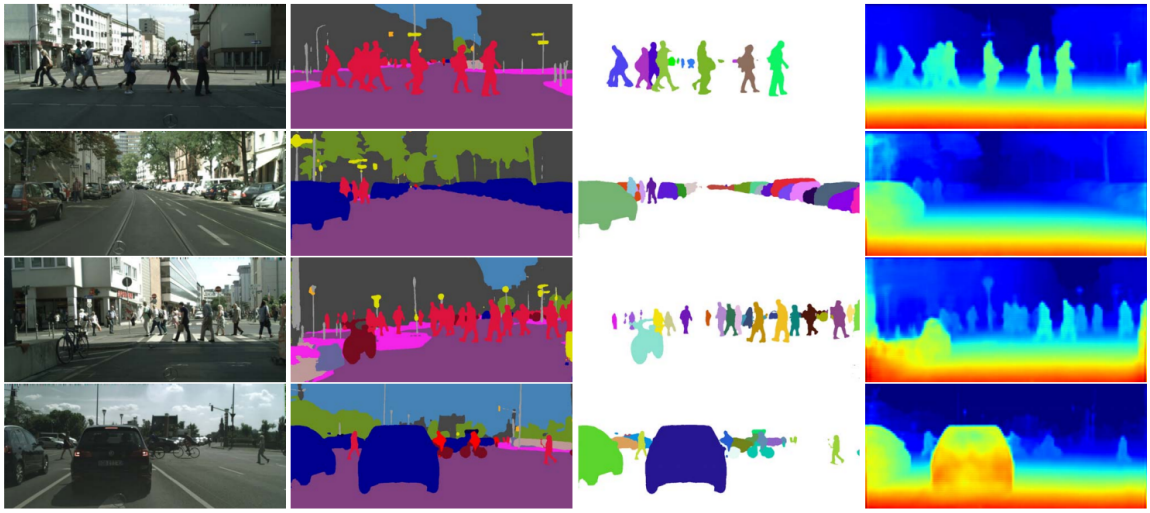

(a) Input image (b) Segmentation output (c) Instance output (d) Depth output

شکل ۳.۳: مثالی از نتایج ساختار چندوظیفه ای مقاله [۵]

فصل ۴ وب اپلیکیشن

از دو روش برای ساختن وب اپلیکشن پروژه استفاده کردیم که در ادامه معرفی می‌شوند.

۱.۴ Streamlit

برای اجرای این قسمت پس از دانلود وزن های مدل YOLO-v3 و نیز مدل و وزن های مدل آموزش داده شده Unet و قرار دادن آن‌ها در پوشه‌های مورد نظر (برای این کار تنها کافیست کدهای نوشته شده در `README.md` را به ترتیب اجرا کنید، این وزن‌ها به دلیل اینکه حجمشان بیشتر از ۱۰۰ مگابایت بود امکان آپلود در گیت‌هاب نداشتند.) کد streamlit `./src/app.py run` را اجرا کنید تا برنامه روی لوکال هاست شما اجرا شود. تعدادی از تصاویر داده شده به این وب اپلیکیشن را می‌توانید در شکل ۱.۴ ببینید:

۲.۴ Django

برای اجرای این قسمت پس از دانلود وزن‌های مدل YOLO-v3 و قرار دادن آن‌ها در پوشه مورد نظر (برای این کار تنها کافیست کدهای نوشته شده در `README.md` را به ترتیب اجرا کنید، این وزن‌ها به دلیل اینکه حجمشان بیشتر از ۱۰۰ مگابایت بود امکان آپلود در گیتهاب نداشتند.) کدهای ذکر شده در `README.md` را اجرا کنید تا برنامه روی لوکال هاست شما اجرا شود. تعدادی از تصاویر داده شده به این وب اپلیکیشن را میتوانید در شکل ۲.۴ ببینید:

۳.۴ چالش ها

با توجه به این که باکس تشخیص داده شده توسط مدل تشخیص اشیاء لزوما شامل تصویر ما نیست (یک مستیطیل تماما انسان را تصور کنید!) برای اندازه‌گیری عمق، مستطیل داخلی باکس (هر ضلع سی درصد مستطیل تشخیص داده شده ی اصلی) را در نظر گرفتیم. برای پیشرفت کد و ادامه ی آن می‌توان مناطق مختلف تصویر را با توجه به کلاسی که تشخیص می‌دهیم در نظر گرفت یا خیر. برای مثال در تشخیص انسان با توجه به این که عمق انسان در تصویر تنها یک عدد است الگوریتم را تغییر نمیدهیم، اما در تشخیص میز با توجه به تغییر عمق آن میتوان یک عمق ابتدایی و انتهایی برای در نظر

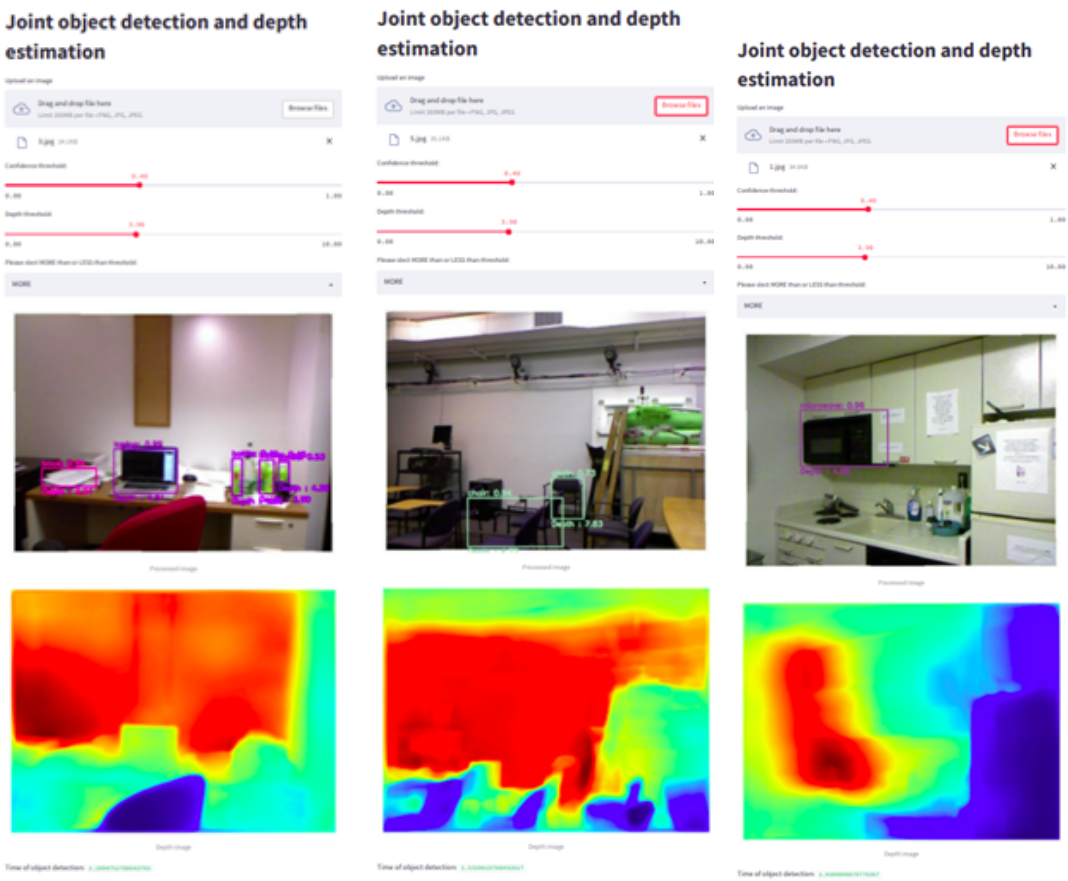

شکل ۱.۴: نمونه های اجرای وب اپلیکیشن در حالت streamlit

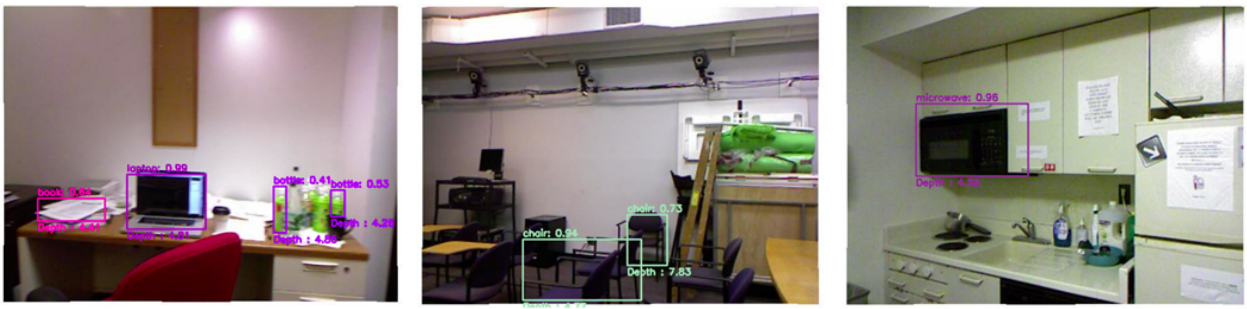

شکل ۲.۴: نمونه های اجرای وب اپلیکیشن در حالت Django

گرفت تا تشخیص آن دقیق‌تر باشد.

الگوریتم پیاده شده ما بر اساس مقاله ذکر شده در صورت پروژه است که مقدار را به روش زیر محاسبه کرده‌است:

$$disp_{mean}^{object} = \frac{1}{0.4w \times 0.4h} \times \sum_{cx-0.2w}^{cx+0.2w} \sum_{cy-0.2h}^{cy+0.2h} disp(i,j)$$

ریت مستطیل داخلی یک هایپرپارامتر است که ما هر ضلع را برابر سی درصد مسطیل تشخیص داده شده در نظر گرفتیم. روش دیگر ارایه شده توسط مقاله به دست آوردن median مقادیر بود:

$$disp_{median}^{object} = median\{disp(i,j) | (i,j) \in BB\}$$

مراجع

[1] Zhu, Jun-Yan, Park, Taesung, Isola, Phillip, and Efros, Alexei A. Unpaired image-to-image translation using cycle-consistent adversarial networks, 2020.

[2] Alhashim, Ibraheem and Wonka, Peter. High quality monocular depth estimation via transfer learning, 2019.

[3] Ruder, Sebastian. An overview of multi-task learning in deep neural networks, 2017.

[4] Zhang, Yu and Yang, Qiang. A survey on multi-task learning. *IEEE Transactions on Knowledge and Data Engineering*, pp. 1–1, 2021.

[5] Kendall, Alex, Gal, Yarin, and Cipolla, Roberto. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics, 2018.